## Programování 1 pro matematiky

# 13. cvičení, 010-01-2024

#### Obsah:

- 0. Farní oznamy
- 1. Úvod: numpy, pandas, matplotlib
- 2. Numpy
- 3. Pandas

## Farní oznamy

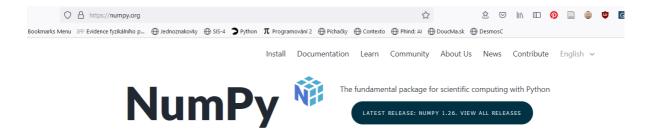
- 1. **Materiály k přednáškám** najdete v GitHub repozitáři <a href="https://github.com/PKvasnick/Program">https://github.com/PKvasnick/Program</a> ovani-1. Najdete tam také kód ke cvičením a pdf soubory textů cvičením.
- 2. Domácí úkoly pokud vám chybí body k zápočtu, dobrý čas s tím něco dělat je teď.
- 3. Kde se nacházíme Končíme.
- 4. **Poznámka ke dnešnímu cvičení** Pro demonstraci používáme Jupyter notebook. Google Colab notebook vám poslouží stejně dobře. Hlavní důvod jsou grafy, vše ostatní vám poběží i v textovém prostředí.

## Úvod

Dnes se seznámíme se třemi Pythonskými balíčky, které tvoří zákklad ekosystému pro technické počítání v Pythonu:

• **numpy** je základní modul, který je "dependencí" pro ostatní moduly. Podporuje vícerozměrná pole, algebru nad nimi, lineární algebru, speciální funkce, optimalizaci, náhodné generátory, podporu hardwaru ,(GPU) a ještě mnoho jiných věcí.

Dolumentace: www.numpy.org



### NumPy 1.26.0 released 2023-09-16

#### POWERFUL N-DIMENSIONAL ARRAYS

Fast and versatile, the NumPy vectorization, indexing, and broadcasting concepts are the de-facto standards of array computing today.

#### INTEROPERABLE

NumPy supports a wide range of hardware and computing platforms, and plays well with distributed, GPU, and sparse array libraries.

#### NUMERICAL COMPUTING TOOLS

NumPy offers comprehensive mathematical functions, random number generators, linear algebra routines, Fourier transforms, and more.

#### PERFORMANT

The core of NumPy is well-optimized C code. Enjoy the flexibility of Python with the speed of compiled code.

#### **OPEN SOURCE**

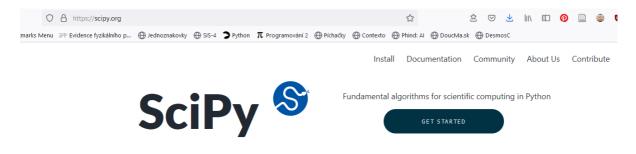
Distributed under a liberal <u>BSD license</u>, NumPy is developed and maintained <u>publicly on GitHub</u> by a vibrant, responsive, and diverse <u>community</u>.

#### **EASY TO USE**

NumPy's high level syntax makes it accessible and productive for programmers from any background or experience level.

Numpy zabezpečuje také integraci C/C++ a Fortranského kódu s Pythonem.

Úzce navázaný na modul numpy je modul **SciPy**. Obsahuje řadu základních algoritmů, rozšiřujících (nebo duplikujících) numpy .



### SciPy 1.11.4 released! 2023-11-18

#### FUNDAMENTAL ALGORITHMS

SciPy provides algorithms for optimization, integration, interpolation, eigenvalue problems, algebraic equations, differential equations, statistics and many other classes of problems.

### PERFORMANT

SciPy wraps highly-optimized implementations written in low-level languages like Fortran, C, and C++. Enjoy the flexibility of Python with the speed of compiled code.

#### BROADLY APPLICABLE

The algorithms and data structures provided by SciPy are broadly applicable across domains.

### EASY TO USE

SciPy's high level syntax makes it accessible and productive for programmers from any background or experience level.

#### FOUNDATIONAL

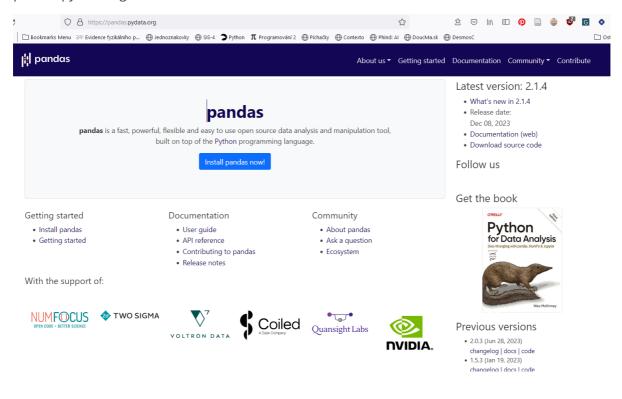
Extends NumPy providing additional tools for array computing and provides specialized data structures, such as sparse matrices and k-dimensional trees.

### OPEN SOURCE

Distributed under a liberal <u>BSD license</u>, SciPy is developed and maintained <u>publicly on GitHub</u> by a vibrant, responsive, and diverse <u>community</u>.

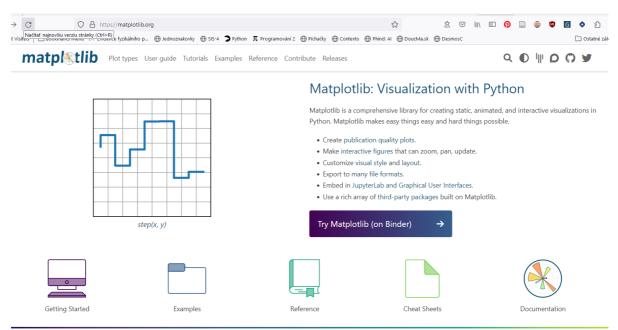
• **Pandas** je modul, definující datové tabulky a operace s nimi. Datové tabulky jsou specifické datové objekty pro zpracování dat a blíž než k maticím mají k Excelovským listům

### pandas.pydata.org



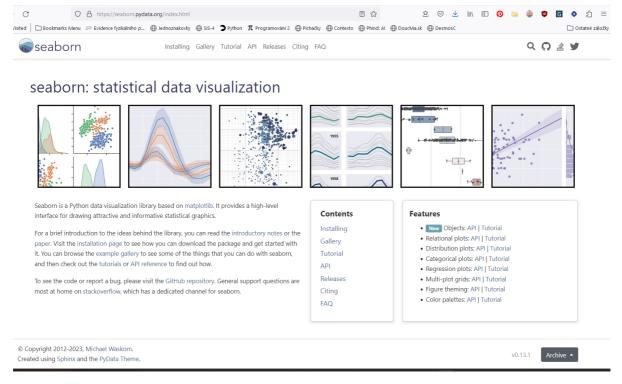
• **matplotlib** je základní knihovna pro vytváření grafů. Má API pro různé jazyky, ale nejširší použití má právě v Pythonu. Podporuje širokou škálu vyjádřovacích možností, typú grafů atd. Je také základnou pro další grafické knihovny.

### matplotlib.org



Tento modul nemá vyhrazenou speciální část v následujícím výkladu - je to tím, že ho budeme používat pro grafické znázornění výsledků pro ostatní dva moduly.

• **seaborn** je nadstavbou matplotlib a obsahuje bohatou galerii grafů pro explorativní analýzu datových tabulek.



#### Instalace

Základní možnost je instalovat moduly pomocí pip (pip install numpy pandas matplotlib). Instalace chvíli trvá, moduly jsou veliké a mají další závislosti.

Lepší je proto instalovat nějakou distribuci, která obsahuje tyto moduly a jejich dependence, například anaconda.

## numpy

```
import numpy as np
```

Toto je standardní způsob importu modulu *numpy* a i když není povinný, je rozumné ho používat. Stejně tak máme standardní způsoby importu dalších modulů:

```
import pandas as pd
import matplotlib.pyplot as plt
```

## numpy array

numpy podporuje vícerozměrná pole a operace s nimi.

numpy array lze vytvořit více způsoby:

```
# Vytváříme numpy pole:

# 1. Konverzí seznamu a úpravou tvaru
a = np.arange(12).reshape(3,4)
print("a", a)
a [[ 0 1 2 3]
```

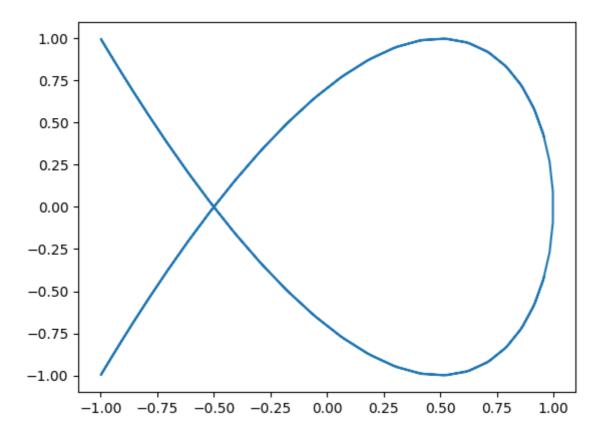
```
[ 4 5 6 7]
 [ 8 9 10 11]]
# 2. Zadáním dimenze: prázdné pole
b = np.ndarray((3,4))
print("b", b)
b [[0.0e+000 4.9e-324 9.9e-324 1.5e-323]
 [2.0e-323 2.5e-323 3.0e-323 3.5e-323]
 [4.0e-323 4.4e-323 4.9e-323 5.4e-323]]
# 3. Specializovaným konstruktorem
c = np.zeros((3,4))
print("c",c)
c [[0. 0. 0. 0.]
 [0. 0. 0. 0.]
[0. 0. 0. 0.]]
d = np.ones((3,4))
print("d", d)
d [[1. 1. 1. 1.]
 [1. 1. 1. 1.]
 [1. 1. 1. 1.]]
```

## Vytváření sekvencí:

```
np.arange - jako range, ale vytváří np.array
np.linspace - pravidelné číselné řady:
```

#### Kreslíme

```
import matplotlib.pyplot as plt
x = np.linspace(-3,3, 100, endpoint = True)
plt.plot(np.cos(2*x), np.sin(3*x))
```



np.sin, np.cos jsou vektorizované verze math.sin, math.cos a numpy má takovýchto vektorizovaných verzí od běžných funkcí mnoho a umožňuje vytvářet vlastní.

## operace s poli

```
print(a)
arev = np.arange(11,-1,-1).reshape(3,4)
print(arev)
print(a+arev)
print(a*arev)
print(a / arev)
[[ 0 1 2 3]
[4567]
[ 8 9 10 11]]
[[11 10 9 8]
[7 6 5 4]
[ 3 2 1 0]]
[[11 11 11 11]
[11 11 11 11]
[11 11 11 11]]
[[ 0 10 18 24]
[28 30 30 28]
[24 18 10 0]]
              0.1
                         0.2222222 0.375
                                               ]
[ 0.57142857  0.83333333  1.2
                              1.75
                                               ]
 [ 2.66666667 4.5
                        10.
                                            inf]]
<ipython-input-20-1a385f80933a>:7: RuntimeWarning: divide by zero encountered in
divide
 print(a / arev)
```

Všechny operace jsou mezi odpovídajícími prvky polí, tedy ne matickvé operace. Ty si musíme explicitně vyžádat.

Co když nesouhlasí rozměry?

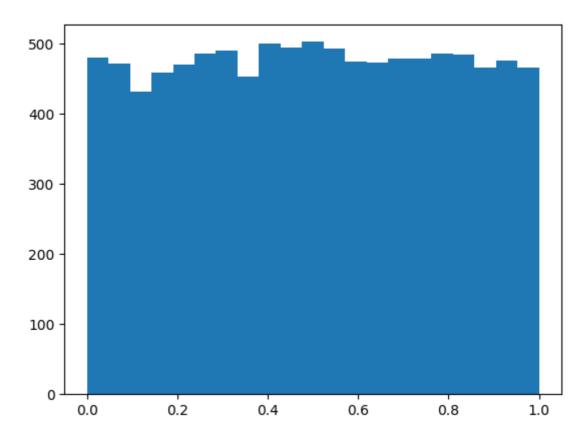
```
v = np.arange(1,4).reshape(3,1)
print(v)
print(a*v)
print(v*a)
---
[[1]
  [2]
  [3]]
[[ 0  1  2  3]
  [ 8  10  12  14]
  [24  27  30  33]]
[[ 0  1  2  3]
  [ 8  10  12  14]
```

Chybějící data se inteligentně doplní (pravidla jsou velice komplexní) - broadcasting

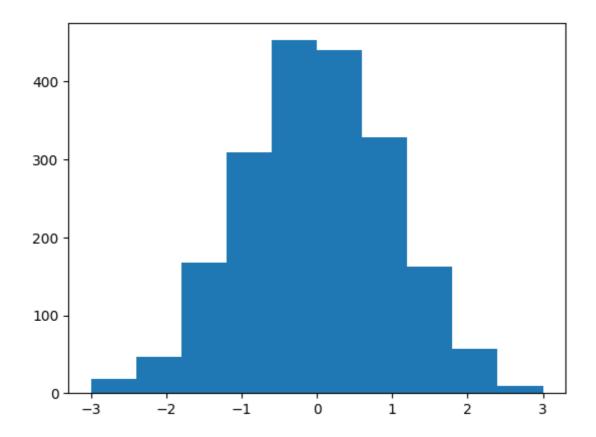
Iterace pres pole:

```
for i in a:
  print(i)
for i in np.nditer(a):
  print(i)
[0 1 2 3]
[4 5 6 7]
[ 8 9 10 11]
0
1
2
3
4
5
6
7
8
9
10
11
```

## Náhodné generátory v numpy



```
plt.hist(rng.standard_normal(2000), bins=np.linspace(-3,3,11,endpoint=True))
---
(array([ 18., 47., 168., 309., 453., 441., 329., 162., 57., 9.]),
    array([-3., -2.4, -1.8, -1.2, -0.6, 0., 0.6, 1.2, 1.8, 2.4, 3.]),
    <BarContainer object of 10 artists>)
```



# Lineární algebra

```
a = np.arange(10).reshape(5,2)
print(a)
b = np.arange(6).reshape(2,3)
print(b)
print(np.matmul(a, b))
[[0 1]
[2 3]
 [4 5]
 [6 7]
 [8 9]]
[[0 1 2]
[3 4 5]]
[[ 3 4 5]
 [ 9 14 19]
 [15 24 33]
 [21 34 47]
 [27 44 61]]
```

```
[[ 1. 1. -1.]

[-0. -1. 1.]

[ 0. 0. 1.]]

[[1. 0. 0.]

[ 0. 1. 0.]

[ 0. 0. 1.]]
```

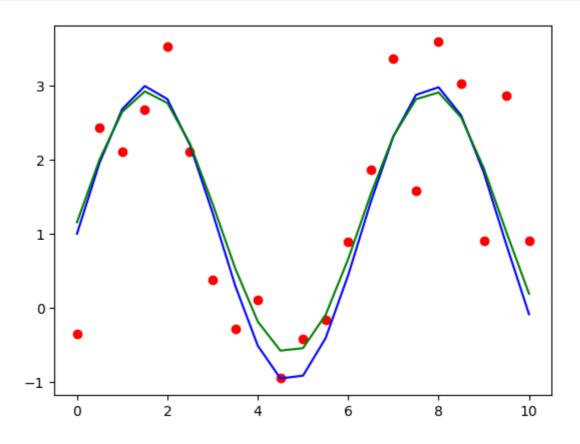
### Lineární regrese

```
x = np.linspace(start=0,stop=10, num=21, endpoint = True)
y0 = 2.0*np.sin(x) + 1.0
y = y0 + np.random.standard_normal(21)
plt.plot(x,y0, "b")
plt.scatter(x,y, color = "r")
F = np.ndarray((21,2))
F[:,0] = np.sin(x)
F[:,1] = np.repeat(1,21)
print(F)
rhs = y.reshape(21,1)
coeffs, sumsq, cond, sing = np.linalg.lstsq(F,y)
y_fit = np.matmul(F, coeffs)
plt.plot(x, y_fit, "g")
[[ 0. 1.
                        ]
[ 0.47942554 1.
                       ]
[ 0.84147098 1.
                       ]
[ 0.99749499 1.
                       ]
 [ 0.90929743 1.
                       ]
[ 0.59847214 1.
                       ]
 [ 0.14112001 1.
                       ]
 [-0.35078323 1.
                       ]
 [-0.7568025 1.
                        ]
 [-0.97753012 1.
                        ]
```

```
[-0.95892427 1.
 [-0.70554033 1.
                          ]
 [-0.2794155
                          1
 [ 0.21511999 1.
                          1
 [ 0.6569866
                          ]
 [ 0.93799998 1.
                          ]
 [ 0.98935825 1.
                          1
 [ 0.79848711 1.
                          ]
 [ 0.41211849 1.
                          ]
 [-0.07515112 1.
                          1
 [-0.54402111 1.
                          11
<ipython-input-69-72e06b7502cb>:11: FutureWarning: `rcond` parameter will change
to the default of machine precision times \operatorname{``max}(M, N) `` where M and N are the
input matrix dimensions.
```

To use the future default and silence this warning we advise to pass `rcond=None`, to keep using the old, explicitly pass `rcond=-1`. coeffs, sumsq, cond, sing = np.linalg.lstsq(F,y)

[<matplotlib.lines.Line2D at 0x7880ef1d02b0>]



# pandas

Modul pandas podporuje datové tabulky (DataFrame) a operace nad nimi.

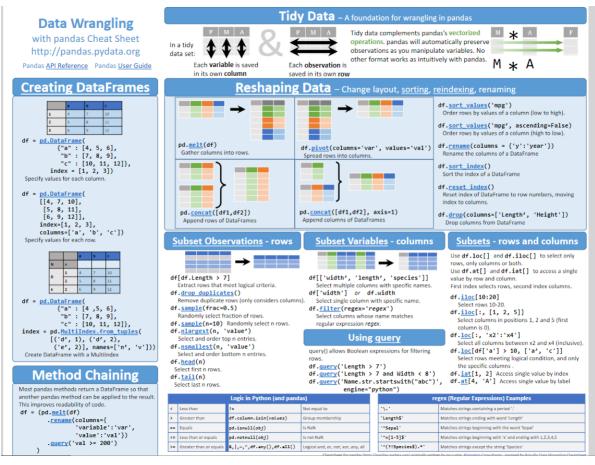
#### 1. Přístup

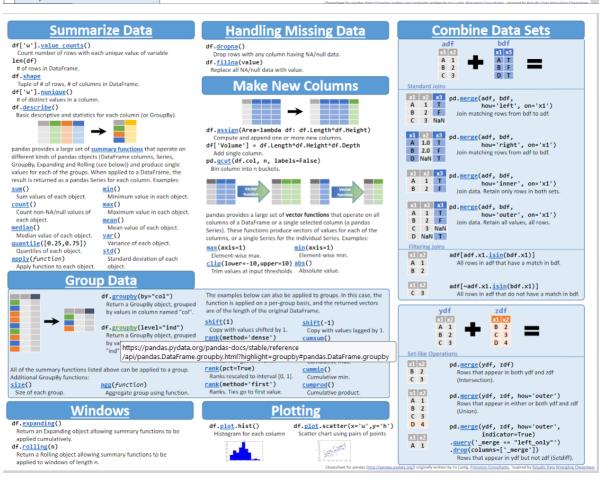
Datové tabulky jsou myšleny jako read-only, tedy se nepředpokládá, že budete chtít měnit hodnoty položek. Můžete ale různě přeskupovat data a přidávat nové sloupce či souhrny. Základní mód zpracování:

$$group \rightarrow apply \rightarrow combine$$
 (1)

#### 2. Struktura

Datové tabulky jsou uchovávány po sloupcích. Proto přidání sloupce je jednoduché, ale přidání řádku je velice časově náročné.





```
data = pd.DataFrame({
   "sex": np.random.choice(["M","F"], 100),
   "group": np.random.choice(["A", "B", "C", "D"], 100),
   "age": np.random.uniform(low = 18, high=90, size = 100)
\}, index = np.arange(100)
)
data["weight"] = data.apply(lambda row: 80 if row.sex == "M" else 60, axis = 1) +
10*np.random.standard_normal(100)
print(data)
                         weight
  sex group
                  age
0
         A 27.189528 80.531588
        в 82.141697 91.257771
1
    М
        в 50.923255 56.787014
2
    F
3
  F
        D 53.439978 62.726728
4
      D 36.728620 94.885223
    М
                           . . . .
                  . . .
       C 80.382851 57.107162
95
   F
96
        D 23.650393 75.769245
    M
        C 30.025270 61.050458
97
    F
    M C 42.891945 70.084252
98
99
        c 20.146695 93.561390
[100 rows x 4 columns]
data.pivot_table(values="weight", index="group", columns = "sex", aggfunc= (len,
np.mean, np.std))
             len
                                              std
                     mean
                 М
                                 Μ
                                                        Μ
     sex
     group
       Α
             15
                10 60.004561 78.863990 8.459412 10.462918
       В
             15 13 57.395915 82.179252 7.277524
                                                         9.864408
             14
                  9 59.403209 82.063862 8.818018
                                                         11.242939
```

### Kreslení pomocí modulu seaborn

D

Modul seaborn obsahuje bohatou galerii grafů pro zkoumání vztahů dat v tabulkách pandas.

7 17 62.933266 79.355646 5.549616 12.609093

